

I. Introducción

El presente trabajo se basó en analizar una base de datos de 117 pacientes con enfermedad de Crohn, una patología inflamatoria intestinal que puede requerir cirugía en casos graves. El objetivo fue explorar qué factores como la edad, el sexo, el tipo de dieta o el número de brotes podrían estar relacionados con la necesidad de cirugía. Para ello, el análisis se dividió en cuatro partes, cada una con un enfoque diferente.

En la primera parte, se realizó un análisis exploratorio de los datos. Esto incluyó describir cada variable por separado mediante gráficos como histogramas, diagramas de caja y diagramas de barras. También se analizaron las relaciones entre pares de variables, por ejemplo, entre el sexo y la cirugía, entre la altura y el peso, o cómo se distribuyen la edad o los episodios según si el paciente fue operado o no.

En la segunda parte, se aplicaron pruebas estadísticas para contrastar hipótesis. Aquí se evaluó si las variables cuantitativas seguían una distribución normal, se calcularon correlaciones entre variables numéricas, se compararon los grupos con y sin cirugía, y se estudió si el índice de masa corporal difería según el tipo de dieta que seguía cada paciente.

La tercera parte consistió en construir un modelo de regresión logística para predecir la probabilidad de necesitar cirugía en función de las demás variables. Se utilizó un método de selección paso a paso para elegir las variables más relevantes, y se evaluó la calidad del modelo mediante indicadores como el porcentaje de acierto y la matriz de confusión.

Finalmente, en la cuarta parte se aplicaron técnicas multivariantes. Por un lado, se realizó un análisis de componentes principales para reducir la dimensión de los datos y visualizar a los pacientes en un plano de dos dimensiones, colocándolos según si necesitaron cirugía. Por otro lado, se llevó a cabo un clustering jerárquico para agrupar a los pacientes por similitud, eligiendo el número óptimo de grupos y representando los resultados con un dendrograma y heatmap. Todo el análisis se realizó utilizando el software RStudio, manejando un total de ocho variables: tres cualitativas, sexo, tipo de dieta y cirugía y cinco cuantitativas edad, altura, peso, índice de masa corporal y número de episodios.

II. Análisis Estadístico


1. Análisis Exploratorio

A continuación se presentan los análisis exploratorios de datos para todas las variables del fichero, tanto descriptivo como gráfico, teniendo en cuenta la naturaleza de cada una, primero se realizó un análisis univariante, y posteriormente uno bivalente, clasificándose en tres subgrupos, categórica vs categórica, numéricas por la variable categórica “surgery”, y numérica vs numérica.

1.1. Análisis Univariante

La figura 1 muestra las frecuencias absolutas de las tres variables cualitativas: sexo, dieta y cirugía. Se observa que la mayoría de los pacientes son mujeres, un 85.5% frente a 14.5% de hombres. Con respecto a la dieta, esta tiene una distribución más equilibrada, Dieta 1 con 35.0%, Dieta 2 con 31.6% y Placebo con 29.9%. En cuanto a la cirugía, dos tercios de los pacientes un 66.7% no necesitaron cirugía, mientras que un tercio 33.3% sí la requirió.

Figura 1. Distribución de las variables categóricas de la muestra




Nota. Frecuencias absolutas observadas para el sexo, tipo de dieta recomendada y necesidad de cirugía de los pacientes.

El desequilibrio entre sexos implica que, al evaluar la relación entre el sexo y la cirugía, no bastará solo con comparar el mayor número de mujeres operadas, ya que hay más mujeres en la muestra, sino que será necesario calcular porcentajes por grupo y aplicar pruebas estadísticas como Chi-cuadrado. Además, la proporción de pacientes operados (33.3%) es suficientemente amplia para realizar modelos de regresión logística que identifiquen predictores de la cirugía.

La siguiente figura muestra la edad media de la muestra mediante histograma con curva de densidad, diagrama de caja y gráfico Q-Q. La media fue de 53.9 años y la mediana de 54 años, estos son valores muy próximos. También se observa una tendencia leve hacia la derecha, con mayor concentración de pacientes entre 40 y 60 años y una cola derecha que se extiende hasta los 75 años, mientras que la izquierda comienza alrededor de los 20

años. El gráfico Q-Q revela una ligera desviación de los puntos de las colas con respecto a la línea de normalidad.

Figura 2. Análisis de distribución de la Edad




Nota. Histograma con curva de densidad, diagrama de caja y gráfico Q-Q para evaluar la normalidad y dispersión de la edad.

Esta distribución de la figura 2 nos indica que la muestra está compuesta mayoritariamente por personas de mediana edad, con un sesgo moderado ya que tanto la media como la mediana son similares. Este tipo de análisis es importante, ya que nos ayuda en la elección de pruebas estadísticas posteriores, ya que al detectarse una desviación de la normalidad en el gráfico Q-Q, no será adecuado usar pruebas como el t-test para comparar la edad entre grupos, sino el test no paramétrico de Wilcoxon en los análisis inferenciales que involucren la variable edad.

Para la variable IMC presentada en la figura 3, observamos que el Momento 1 (media) se encuentra desplazado hacia la derecha del pico más alto de densidad, mientras que la mediana se mantiene cerca de la masa principal de la distribución, lo que indica una asimetría positiva. En el histograma, a diferencia del gráfico de la edad, se observa un corte abrupto en el valor de IMC $\approx 40 \text{ kg/m}^2$, indicando que los valores extremadamente altos son escasos, por otro lado el diagrama de caja muestra 5 valores atípicos en el lado derecho, esto sugiere una distribución con colas más pesadas. Finalmente, el gráfico Q-Q plot confirma desviaciones en los extremos respecto a la línea de normalidad, especialmente en la cola superior, consistente con la asimetría observada.


Figura 3. Análisis de distribución del Índice de Masa Corporal (IMC).



Nota. Evaluación gráfica de la distribución del IMC, destacando asimetría positiva y presencia de valores atípicos superiores.

Con respecto al número de episodios de la figura 4, el diagrama de barras muestra una asimetría positiva, el pico de frecuencia se concentra al inicio del eje, entre los puntos 0 y 3, además los valores más frecuentes son 0 episodios y una frecuencia de 35, y en segundo lugar el número de episodios 2 con una frecuencia de 26, la distribución se extiende hasta los 12 episodios, aunque con frecuencias muy bajas en valores altos, y se observa un salto de 9 a 12 episodios, ya que no se registraron pacientes con 10 ni 11 episodios en la muestra.

Figura 4. Análisis de distribución del Número de Episodios



Nota. Distribución de frecuencias de la variable discreta número de episodios.

El boxplot muestra la falta de homogeneidad de los datos, ya que el 50% de los datos se encuentra comprimido en un rango muy pequeño $Q1 = 0$ y $Q3 = 3$, además los valores atípicos representan casos con un número de episodios alto respecto al resto de la muestra, lo que indica la existencia de pacientes con una carga de enfermedad significativamente mayor.


Finalmente, el gráfico Q-Q plot muestra que, a diferencia de las variables anteriores, los puntos se dispersan marcadamente hacia arriba respecto a la línea de normalidad. Esta desviación se debe a que el número de episodios es una variable discreta y se encuentra concentrada en valores bajos, esto evita un comportamiento normal en su distribución, indicando que los pacientes tienden a tener entre 0-2 episodios y que es más probable tener 2 episodios a uno solo.

1.2. Análisis Bivariante

1.2.1. Categórica vs categórica

El análisis de la relación entre el sexo y la necesidad de cirugía indicó un desbalance muestral importante entre 100 mujeres, 85.5% y únicamente 17 hombres, 14.5%. Para evaluar la asociación de forma justa, se calcularon los porcentajes dentro de cada grupo, el 35% de las mujeres (35 de 100) requirió cirugía, mientras que en los hombres este porcentaje fue del 23.5% (4 de 17). A pesar de esta diferencia aparente, la prueba de Chi-cuadrado no mostró una asociación estadísticamente significativa entre el sexo y la cirugía ($\chi^2 = 0.42$, $gl = 1$, $p = 0.516$).

Figura 5. Necesidad de cirugía según sexo y tipo de dieta



De acuerdo con los datos sobre la necesidad de cirugía respecto a la dieta, se obtuvo que la Dieta 1 tiene un porcentaje del 26.8% (11/41), la Dieta 2 un 35.1% (13/37) y el Placebo un 25.0% (5/20). Aunque la Dieta 2 presentó el porcentaje más alto, la prueba de Chi-cuadrado demostró que no existe una asociación estadísticamente significativa entre ambas variables ($\chi^2 = 0.11$, gl = 2, $p = 0.946$).


Esta distribución refleja que, aunque en números absolutos las mujeres operadas sean más, esto se debe principalmente a que hay muchas más mujeres en la muestra, y no necesariamente a que el sexo influya en la cirugía. Del mismo modo, las pequeñas diferencias entre dietas podrían deberse simplemente a la variabilidad muestral. Para detectar asociaciones reales entre variables categóricas, no solo se deben comparar frecuencias absolutas cuando los tamaños de los grupos son desiguales, sino que es necesario calcular porcentajes dentro de cada grupo y aplicar la prueba de Chi-cuadrado, que evalúa si las diferencias observadas son estadísticamente significativas o pueden explicarse por el azar.

1.2.2. Numérica vs categórica (surgery)

En el siguiente bloque se analizó la relación entre las variables cuantitativas y la necesidad de cirugía mediante diagramas de caja. Para fortalecer el análisis y evitar sesgos, se realizó la prueba de Wilcoxon, más robusta ante distribuciones asimétricas y valores atípicos.

La figura 6 presenta cinco diagramas de caja que comparan la distribución de las variables cuantitativas entre los pacientes que requirieron cirugía y los que no. Al analizar la edad, se observa que la mediana del grupo con cirugía es superior a 60 años, y la del grupo sin cirugía 54 años. En el número de episodios, la diferencia es más significativa, la mediana del grupo con cirugía es de 2 episodios, mientras que la del grupo sin cirugía es de 1 episodio, y las cajas muestran una separación más clara, en cambio para el IMC, las medianas son casi iguales con 25.21 vs 24.96 kg/m² y las cajas se superponen casi por completo, similarmente en la altura, las medianas son cercanas con 163 cm sin cirugía vs 160 cm con cirugía, con un amplio solapamiento de las cajas. Finalmente, el peso también muestra medianas próximas con 69 kg vs 65 kg y una superposición considerable entre ambos grupos.

Figura 6. Distribución de variables cuantitativas según necesidad de cirugía



Nota. Diagramas de caja comparativos. Destacan las diferencias medianas en la edad y el número de episodios entre los grupos.


Las diferencias observadas indican que los pacientes operados tienden a ser mayores y a haber sufrido más episodios que los no operados, mientras que el IMC, la altura y el peso no parecen distinguir claramente entre ambos grupos. Esta tendencia visual sugiere que la edad y la carga de enfermedad medida por el número de episodios, podrían estar relacionadas con la probabilidad de requerir cirugía, algo que deberá confirmarse mediante pruebas estadísticas. Estos datos permiten identificar visualmente qué variables cuantitativas podrían estar asociadas con la cirugía antes de implementar hipótesis formales.

El resumen de la mediana, la dispersión y la presencia de valores atípicos presentados por los diagramas de caja, nos indican la clara diferencia entre el número de episodios y la leve diferencia en la edad y justifican la realización de pruebas estadísticas como el test de Wilcoxon en la sección de inferencia. Por el contrario, la ausencia de diferencias notables en el IMC, la altura y el peso sugiere que probablemente no resultaron significativas. Además, estos gráficos complementan el análisis de normalidad previo, ya que la presencia de valores asimétricos o atípicos refuerza la necesidad de utilizar pruebas no paramétricas.

Las curvas de densidad de la figura 7, muestran curvas superpuestas que comparan la distribución de edad, altura y peso entre pacientes con y sin cirugía, con respecto a la edad

la curva del grupo con cirugía se desplaza hacia la derecha, con un pico en 60 años frente a los 50-55 años del grupo sin cirugía, lo que indica que los pacientes operados son de mayor edad. En cambio, las curvas de altura y peso se superponen casi por completo entre ambos grupos, con picos centrados en valores similares (160-165 cm y 65-70 kg respectivamente).

Figura 7. Curvas de densidad según necesidad de cirugía








1.2.3. Numérica vs numérica

A continuación se presentan seis diagramas de dispersión que muestran visualmente la relación entre las variables cuantitativas: edad, IMC, número de episodios, altura y peso. Cada punto representa un paciente y la línea roja superpuesta indica la tendencia lineal ajustada. En la mayoría de los paneles se observa una nube de puntos muy dispersa sin una dirección clara. La única excepción es el gráfico que relaciona altura y peso, donde sí se aprecia una tendencia positiva moderada, indicando que a mayor altura, mayor peso. En los paneles de edad vs. IMC, edad vs. episodios, IMC vs. episodios, altura vs. IMC y peso vs. episodios, los puntos se distribuyen aleatoriamente y las líneas de tendencia son planas o con pendientes muy suaves, lo que indica asociaciones débiles o nulas.

Esta distribución indica que la altura y el peso están relacionados, ya que las personas más altas tienden a pesar más, mientras que el resto de las variables analizadas no presentan una relación lineal evidente. El número de episodios, en particular, parece comportarse de manera independiente respecto a la edad, el IMC y el peso, lo que sugiere que la carga de enfermedad no está asociada linealmente con las características físicas de los pacientes.

Figura 8. Diagramas de dispersión entre pares de variables numéricas.





Nota. Gráficos de dispersión y coeficientes de correlación entre edad, IMC, episodios, altura y peso.

2. Inferencia Estadística

2.1. Contrastes de normalidad

Se evaluó el supuesto de normalidad de las variables cuantitativas edad, IMC, número de episodios, altura y peso, mediante la prueba de Shapiro-Wilk ($\alpha = 0.05$). Como se muestra en la Tabla 1, ninguna de las cinco variables cumplió con el supuesto de normalidad. La edad presentó un estadístico $W = 0.974$ ($p = 0.024$), el IMC $W = 0.932$ ($p < 0.001$), la altura un $W = 0.971$ ($p = 0.012$), el peso un $W = 0.967$ ($p = 0.006$), y el número de episodios $W = 0.818$ ($p < 0.001$) siendo esta la variable con mayor desviación.

Dado el incumplimiento de la normalidad, se optó por utilizar pruebas no paramétricas para los análisis inferenciales, en concreto, se empleó el test de Wilcoxon para comparaciones de dos grupos independientes, el test de Kruskal-Wallis para comparaciones de más de dos grupos, y el coeficiente de correlación de Spearman en lugar del de Pearson para el estudio de las correlaciones.


Tabla 1. Resumen de las pruebas de normalidad de Shapiro-Wilk

Análisis	Variable_dependiente	Factor	Test	Estadístico	p_valor	Conclusión
Normalidad	Edad	-	Shapiro-Wilk	W = 0.974	0.0235	NO normal
Normalidad	IMC	-	Shapiro-Wilk	W = 0.932	< 0.001	NO normal
Normalidad	Episodios	-	Shapiro-Wilk	W = 0.818	< 0.001	NO normal
Normalidad	Altura	-	Shapiro-Wilk	W = 0.971	0.0115	NO normal
Normalidad	Peso	-	Shapiro-Wilk	W = 0.967	0.0059	NO normal

2.2. Estudio de la matriz de correlaciones

En este punto se exploraron las asociaciones entre la edad, altura, peso, IMC y el número de episodios. Debido al incumplimiento del supuesto de normalidad, se empleó el coeficiente de correlación de Spearman ya que esta ofrece mayor robustez frente a distribuciones asimétricas y valores atípicos.

Figura 9. Matriz de correlación de Spearman



Nota. Mapa de calor que ilustra la fuerza y dirección de las asociaciones monótonas.

La matriz indica una correlación fuerte entre el peso y el IMC ($\rho = 0.84$), dado que el IMC se calcula a partir del peso y la altura. También se encontró una correlación moderada y positiva entre la altura y el peso ($\rho = 0.51$), el número de episodios mostró correlaciones débiles con el resto de variables, positiva con la edad ($\rho = 0.24$) y el IMC ($\rho = 0.15$), y negativa con la altura ($\rho = -0.17$). Ninguna de estas correlaciones parece tener importancia estadística, esto plantea que la frecuencia de episodios no está asociada linealmente con las características antropométricas de los pacientes.

Otro punto importante es que la edad no presentó correlaciones relevantes con ninguna de las otras variables cuantitativas, ya que únicamente tiene coeficientes cercanos a cero. Esto indica que, en esta muestra, la edad es independiente de las medidas corporales y del número de episodios.

2.3. Diferencias según necesidad de cirugía

La Tabla 2 nos muestra los resultados de la prueba de Wilcoxon, en la que se comparara la edad, IMC y número de episodios entre pacientes con y sin cirugía. El número de episodios mostró una diferencia altamente significativa ($W = 892.5$, $p < 0.001$), siendo mayor en el grupo con cirugía, con medias comparativas de 3.33 vs 1.86. La edad también presentó diferencias significativas ($W = 1099$, $p = 0.015$), con una media de 57.6 años en el grupo con cirugía frente a 53.2 años en el grupo sin cirugía. Por el contrario, el IMC no mostró diferencias significativas entre ambos grupos ($W = 1573.5$, $p = 0.764$).

Tabla 2 Diferencias de edad, IMC y episodios según necesidad de cirugía

Tabla 2. Diferencias según necesidad de cirugía						
Comparación de edad, IMC y número de episodios entre grupos						
Variable	Mediana (Sin cirugía)	Mediana (Con cirugía)	Media (Sin cirugía)	Media (Con cirugía)	p-valor (Wilcoxon) [†]	Conclusión (α = 0.05)
Edad (años)	54.00	60.00	53.20	57.60	0.0147	Significativo
IMC (kg/m ²)	25.21	24.96	25.84	26.30	0.7637	No significativo
Numero de episodios	1.00	2.00	1.86	3.33	< 0.001	Significativo

[†] Se utilizó la prueba de Wilcoxon debido a la falta de normalidad en las variables.

Estos resultados indican que una mayor carga de enfermedad y una edad más avanzada se asocian significativamente con la necesidad de cirugía. En contraste, el IMC no parece ser un factor determinante en esta muestra, lo que sugiere que la decisión quirúrgica está más relacionada con la actividad de la enfermedad que con el estado nutricional del paciente. Estos resultados orientan los siguientes análisis ya que han identificado al número de episodios como el principal predictor de la cirugía en el modelo de regresión logística.

2.4. ANOVA y post-hoc: IMC según tipo de dieta

En este punto, se investigó si existían diferencias en el IMC según el tipo de dieta Dieta 1, Dieta 2, y Placebo mediante ANOVA de un factor. La hipótesis nula indica que las medias poblacionales del IMC son iguales en los tres grupos, mientras que la hipótesis alternativa plantea que al menos una de las medias difiere del resto.

Tabla 3 Resultados del ANOVA y análisis post-hoc para IMC según dieta

Tabla 3. Resultados del ANOVA y análisis post-hoc				
IMC según tipo de dieta (Dieta 1, Dieta 2, Placebo)				
Comparación	Estadístico	gl	p.valor	Conclusión
ANOVA global (IMC ~ Dieta)	F = 9.33	2, 114	< 0.001	Significativo
Placebo vs Dieta 1	t	-	< 0.001	Significativo
Placebo vs Dieta 2	t	-	< 0.001	Significativo
Dieta 1 vs Dieta 2	t	-	0.8367	No significativo

El ANOVA mostró que la dieta sí afecta al IMC, debido a que las diferencias entre los grupos de dieta son más grandes de lo que cabría esperar por la variabilidad natural entre individuos. Dado que el p-valor es inferior a 0.05, se rechaza la hipótesis nula de igualdad de medias y se acepta que al menos una de las dietas presenta un IMC medio diferente al de las demás. Las medias de IMC observadas fueron de 24.75 kg/m² para la Dieta 1, 24.95 kg/m² para la Dieta 2 y 28.70 kg/m² para el grupo Placebo, siendo este último el que presenta el valor más elevado.


Por otro lado, El análisis post-hoc con corrección de FDR mostró que el grupo Placebo presenta valores de IMC significativamente diferentes en comparación con la Dieta 1 ($p < 0.001$) y con la Dieta 2 ($p < 0.001$), mientras que no se encontraron diferencias significativas entre la Dieta 1 y la Dieta 2 ($p = 0.837$).

Adicionalmente, el tamaño del efecto medido mediante η^2 , fue de 0.1406, lo cual indica que el 14.06% de la variabilidad total del IMC es explicada por el tipo de dieta. Este valor se considera un efecto grande siguiendo el criterio estándar de $\eta^2 \geq 0.14$, lo que refuerza la relevancia de la dieta como factor influyente sobre el IMC.

3. Regresión

En esta sección se analiza una regresión logística binaria dado que la variable “cirugía” es dicotómica Sí/No. Se incluyeron como potenciales predictoras las variables edad, IMC, N° de episodios, sexo y dieta, excluyendo altura y peso por su redundancia con el IMC. Para seleccionar el conjunto de predictores, se empleó el método de selección paso a paso bidireccional stepwise, basado en el criterio de información de Akaike (AIC), que evalúa la mejora del modelo al añadir o eliminar variables.

Figura 10. Gráfico de influencia y valores atípicos del modelo de regresión logística



El proceso stepwise eliminó sucesivamente las variables dieta, IMC y sexo, resultando en el modelo final "cirugía ~ edad + episodios". En este modelo, el número de episodios resultó muy significativo ($p = 0.014$), con un Odds Ratio de 1.2145 (IC 95% = 1.04-1.43). Esto indica que, manteniendo constante la edad, por cada episodio adicional la probabilidad de requerir cirugía aumenta un 21.5%. Además, la edad mostró un efecto positivo con un OR = 1.037, aunque no alcanzó significación estadística ($p = 0.083$).

El modelo presentó un pseudo R^2 de McFadden de 0.0746, por lo que solo el 7.5% de la variabilidad de la cirugía es explicada por las variables incluidas. La matriz de confusión mostró un porcentaje de acierto global del 65.8%, con una alta especificidad del 88.5% para identificar pacientes que no requieren cirugía, pero una baja sensibilidad del 20.5% para detectar a los que sí la requieren. En conjunto, estos resultados indican que el número de episodios es el factor más relevante asociado a la cirugía, aunque el poder predictivo limitado del modelo sugiere que otros factores clínicos no considerados en este estudio podrían estar influyendo en la decisión quirúrgica.


4. Análisis Multivariante

En esta sección se utilizaron técnicas de reducción de dimensionalidad y de agrupamiento no supervisado para explorar la estructura de los datos. El objetivo principal fue identificar si las variables numéricas (edad, altura, peso, IMC y número de episodios) presentaban correlaciones fuertes entre sí, y si lograban agrupar de forma natural a los pacientes dependiendo de si necesitaron cirugía o no. Para este análisis, todas las variables fueron previamente estandarizadas, eliminando así el efecto de las distintas unidades de medida. A continuación, se detallan los hallazgos obtenidos mediante el Análisis de Componentes Principales y el Clustering Jerárquico.

4.1. Análisis de Componentes Principales PCA

Para determinar cuántas componentes principales son necesarias para resumir adecuadamente la información de las variables numéricas se realizó el siguiente análisis:

Figura 11. Varianza explicada por cada componente principal.




El gráfico de sedimentación muestra que las dos primeras dimensiones logran retener el 67.2% de la variabilidad total de los datos originales, seguida de la Dimensión 1 con un 39.8% y 27.4% en la Dimensión 2. Esto valida el uso de un plano bidimensional para representar adecuadamente la dispersión de la muestra.

Por otro lado, la figura 12, muestra un biplot que proyecta simultáneamente los pacientes (puntos) y las variables (flechas) sobre el plano definido por las dos primeras componentes principales, Dim1 con 39.8% de varianza y Dim2 con 27.4%. Los pacientes están coloreados según la necesidad de cirugía: azul = No, y rojo = Sí, y las flechas representan la dirección e intensidad de cada variable numérica. El biplot muestra una correlación positiva muy fuerte entre el peso y el IMC, ya que sus flechas apuntan en la misma dirección y son casi paralelas. En cuanto a los grupos de cirugía, las elipses de confianza del 95% se superponen casi por completo, sin una separación clara entre pacientes operados y no operados.

Este orden refleja que las variables numéricas por sí solas no logran discriminar adecuadamente entre los pacientes que requirieron cirugía y los que no, lo que sugiere que otros factores no incluidos en el PCA como el número de episodios, ya analizado en la regresión logística, podrían ser más relevantes para explicar la cirugía, además, la fuerte correlación entre peso e IMC era esperable, dado que el IMC se calcula a partir del peso y la altura y los resultados de los diagramas de dispersión anteriores.

Gracias a los resultados del biplot, concretamente la superposición de las elipses sabemos que no es posible clasificar a los pacientes según la cirugía utilizando únicamente sus características físicas y metabólicas como la edad, IMC, altura, y peso. Esto orienta el análisis multivariante hacia la búsqueda de otros patrones de agrupamiento o hacia la inclusión de variables clínicas como el número de episodios.

Figura 12. Biplot del análisis de componentes principales.




Nota. Proyección de los individuos (puntos) y las variables (flechas) sobre el plano definido por las dos primeras componentes principales.

4.2. Clustering jerárquico

Para complementar el análisis anterior, se realizó un agrupamiento jerárquico buscando similitudes directas entre las observaciones, para seleccionar el criterio de agrupación más adecuado se evaluó la calidad del particionamiento calculando el coeficiente de correlación cofenética para diversas combinaciones, y se determinó que la métrica de distancia euclídea junto con el método de enlace promedio era lo más óptimo. Al obtener el coeficiente más alto de las pruebas realizadas (0.743), se justifica su uso ya que garantiza la mejor representación estructural de los datos originales.

Figura 13. Métodos para determinar el número óptimo de clústeres.




Nota. Se presentan los resultados del método del codo (WSS), el método de Silhouette y el método Gap statistic.

El gráfico de Silhouette muestra que el valor máximo del coeficiente de silueta se alcanza también en $k = 2$, indicando que los clústeres están mejor definidos con esta partición. El

hecho de que $k = 2$ sea el óptimo sugiere que la muestra presenta una estructura natural en dos grandes grupos, uno de los cuales podría estar influenciado por la presencia de valores atípicos en variables como el IMC, tal como se observó en la Figura 3.

Figura 14. *Dendrograma del clustering jerárquico.*




El clustering jerárquico se generó utilizando la distancia euclidiana como medida de similitud y el average linkage como método de aglomeración. El dendrograma resultante muestra la estructura de agrupamiento de los 117 pacientes en función de sus variables numéricas de edad, IMC, número de episodios, altura y peso.

El árbol de clasificación indica una estructura jerárquica donde, a medida que se asciende en el eje de alturas, los pacientes se van agrupando progresivamente, observándose una división en dos clusters principales azul y rojo, siendo esta la partición seleccionada tras el análisis del número óptimo de grupos. Más que sugerir dos perfiles clínicos equilibrados, la división revela un efecto de chaining, el primer clúster aísla de forma temprana a dos únicos pacientes con valores atípicos extremos con pesos superiores a 110 kg e IMC mayor a 42, mientras que el segundo clúster aglomera secuencialmente a los 115 pacientes restantes, representando el continuo cuantitativo del perfil estándar de la cohorte.

La división en dos clústeres es consistente con el número óptimo de grupos determinado en la Figura 13 ($k = 2$). Además, la separación temprana de un pequeño grupo de pacientes podría estar reflejando la presencia de valores atípicos en el IMC identificados anteriormente.

Con respecto a la proyección del PCA de la figura 15, se observan dos componentes principales, Dim1 con 39.8% de varianza y Dim2 con 27.4%. Cada punto representa un paciente, y los colores indican la pertenencia a cada clúster, las elipses representan intervalos de confianza del 95% para cada grupo, también se observa una separación clara entre ambos clústeres a lo largo de la Dimensión 1, el Clúster 1 se concentra en la parte negativa de Dim1, mientras que el Clúster 2 se ubica en la parte positiva, adicionalmente la elipse del Clúster 2 es más alargada, indicando una mayor dispersión de los pacientes en ese grupo.

Figura 15. *Proyección PCA de los clústeres obtenidos ($k = 2$).*




Esta proyección permite relacionar la pertenencia a cada clúster con la posición de los pacientes respecto a las variables originales (ver Figura 12), esto ayuda a interpretar qué características definen a cada grupo. Por ejemplo, dado que el Clúster 1 se ubica en la parte negativa de Dim1 y el Clúster 2 en la parte positiva, y sabiendo por la Figura 12 que el peso y el IMC tienen cargas positivas en Dim1, se puede inferir que el Clúster 2 agrupa a los pacientes con mayor peso e IMC, en concordancia con la presencia de valores atípicos ya detectados.

El siguiente heatmap complementa a las figuras anteriores integrando en una sola visualización los valores de las variables, este presenta las cinco variables numéricas estandarizadas, donde cada columna representa un paciente y cada fila una variable, los colores indican la intensidad de los valores, tonos rojizos representan valores altos por encima de la media, tonos azules valores bajos por debajo de la media, y tonos pálidos valores cercanos a la media. En la parte izquierda se incluye una barra de anotación que identifica con rojo a los pacientes que requirieron cirugía y con aqua a los que no, y el dendrograma superior clasifica las variables según su similitud de comportamiento, mientras que el dendrograma izquierdo clasifica a los pacientes.

En la figura 16 se observa que el peso y el IMC se agrupan juntos en el dendrograma superior con una rama muy corta, lo que indica una alta correlación entre ambas variables. En cuanto a los pacientes operados y no operados, estos se distribuyen de forma mixta a lo largo de todo el heatmap, sin formar bloques claramente diferenciados. Esto indica que, aunque los clústeres del dendrograma izquierdo agrupan a los pacientes por similitud general, estos no corresponden directamente con la necesidad de cirugía, confirmando los hallazgos del PCA (Figura 12) donde las elipses de cirugía se superponen casi por completo.

Figura 16. Heatmap de las variables numéricas con anotación de cirugía.



Nota. Mapa de calor de las cinco variables numéricas estandarizadas (edad, IMC, episodios, altura, peso).

El heatmap integra en una sola visualización los valores de las variables, el agrupamiento de pacientes y la cirugía. La distribución mixta de pacientes operados y no operados confirma lo ya observado en las Figuras 12 y 15, las variables numéricas no discriminan claramente la cirugía. Además, el agrupamiento del peso y el IMC en el dendrograma superior valida la alta correlación entre ambas variables detectada en la Figura 9.

III. Conclusiones

El análisis exploratorio reveló que la muestra de pacientes con enfermedad de Crohn está compuesta mayoritariamente por mujeres y por personas de mediana edad, con una representación menor de jóvenes y ancianos. El número de episodios se concentra en valores bajos, aunque existen casos con muchos episodios, esto plantea que algunos pacientes tienen una enfermedad más activa o grave, mientras que el IMC mostró que, aunque la mayoría de los pacientes tiene un peso saludable, existe un pequeño grupo con obesidad severa que destaca del resto. Una característica importante para todo el estudio fue que ninguna de las variables cuantitativas sigue una distribución normal, por lo que se utilizaron pruebas estadísticas no paramétricas a lo largo del análisis, desde las comparaciones entre grupos hasta las correlaciones y los modelos predictivos.

Al profundizar en las relaciones entre variables, se observó que el número de episodios y la edad son los factores que más diferencian a los pacientes que requirieron cirugía de los que no, mientras que el sexo, el tipo de dieta y el IMC no mostraron una relación significativa con la necesidad de cirugía. Sin embargo, al construir un modelo de regresión logística para predecir la cirugía, el número de episodios resultó ser el único predictor estadísticamente relevante, aunque no explica gran parte de lo que ocurre es decir que, si bien los pacientes con más brotes tienen una mayor probabilidad de ser operados, la decisión quirúrgica depende también de otros factores que no están en este estudio. Por otro lado, el análisis de la dieta sí mostró un efecto claro sobre el IMC, el grupo Placebo que en promedio estaban en sobrepeso, presentaron valores más altos, mientras que con las dietas 1 y 2 los pacientes se mantuvieron en un peso normal, por lo cual indica que seguir una dieta específica influye positivamente en el estado nutricional de los pacientes.

Para finalizar, las técnicas multivariantes confirmaron que las características físicas de los pacientes como la edad, peso, altura, IMC, por sí solas no logran separar a los operados de los no operados, y que la estructura natural de los datos se organiza en dos grandes grupos, uno de los cuales parece estar influenciado por los valores atípicos de IMC que mencionamos antes. En conjunto, los resultados apuntan a que el número de episodios es el principal indicador asociado a la cirugía. Sin embargo, esto no es suficiente para predecir bien quién va a necesitar una operación, esto plantea que sería importante seguir explorando otras variables clínicas en futuros estudios, como la actividad inflamatoria o la respuesta al tratamiento farmacológico, para entender mejor qué pacientes con enfermedad de Crohn terminan requiriendo una intervención quirúrgica.